RESEARCH PROGRESS REPORT

研究進捗

比較評価計画および自動・手動評価の設計

RELATED WORK

比較する相手の研究

M^6 GPT^3 #2

Pocwiardowski et al., 2024

- **入力形式:** 英語の自由文からマルチトラック MIDI を生成
- **内部パラメータ:** 明るさと激しさの数値パラメータも併用
- **評価軸:** 雰囲気の一致・音楽品質・分布の近さを網羅的に比較

Whole-song-gen #3

Wang et al., 2024

- **生成能力:** 最大 256 小節の長尺な曲生成に対応
- **入力特性:** テキスト入力非対応（ポップ系データで学習）
- **評価軸:** 音楽品質および分布の近さの 2 軸で比較
- **補足:** 入力スタイルの差は論文中に明記して整理

AUTOMATIC EVALUATION METRICS

自動評価の方法：FAD と MAD

生成された楽曲が「人間の演奏にいかに近いか」を数値化する 2 種類の指標を使用

FAD (フレシェ音声距離)

- **変換モデル:** 音楽と言葉の両方で学習した数値変換モデルを使用
- **計算手法:** 数百曲分のデータをまとめた分布と参照分布の距離を算出
- **判定基準:** 数値が**小さいほど参照（人の演奏）に近い**

MAD (マウブ音声発散)

- **変換モデル:** 音楽専用の自己学習モデルを特徴抽出に適用
- **計算手法:** 言語モデルの評価手法を転用し分布間距離を計算
- **特長:** FAD より**人の好みとの対応度が高い**研究報告あり

METRIC FUNDAMENTALS

FAD と MAD：自動評価指標の概要

生成した音楽が「人が好む音楽の分布に近いか」を客観的に自動測定する

集合データ単位の評価

1曲単位の採点ではなく、**100曲以上をまとめて1つの数値**（分布間距離）として算出

数値解釈の原則

距離を示す指標のため、数値が**小さいほど参照（人の演奏）の分布に近い**

主観評価との高い適合

「人間が聴いて好むか」という実効的評価と高い相関を持つ学術的裏付けを保持

指標選定のねらい

単一の曲の偶発的な品質ではなく、モデルの持つ生成能力全体の「自然さ・人間らしさ」を統計的な分布比較によって客観評価します。

FAD MECHANISM

FAD (フレシェ音声距離) の仕組み

特徴抽出モデル：CLAP

- **学習構造:** 音楽と説明テキストのペアによる対照学習モデル
- **ベクトル化:** 音声を **512次元の数値ベクトル** に変換
- **意味情報:** 「明るい」「激しい」といった雰囲気的印象も数値へ反映

WAV File → CLAP Encoder → [0.12, -0.34, 0.87, ..., 0.05]
※ 100曲分をまとめて「多変量正規分布」として近似

計算式と数値の評価

$$\mathrm{FAD} = \mathrm{m}_1 - \mathrm{m}_2^{\,2} + \mathrm{Tr}\Sigma_1 + \Sigma_2 - 2\sqrt{\Sigma_1 \Sigma_2}$$

- **m_1, m_2:** 参照曲・生成曲ベクトルの平均（中心位置のズレ）
- **Σ_1, Σ_2:** 分布の広がり（分散・共分散行列）、**Tr:** 行列の対角和

FAD の値	意味
数値が小さい	生成曲の分布が参照（人の演奏）に**近い**
数値が大きい	生成曲の分布が参照（人の演奏）から**遠い**

MAD MECHANISM

MAD (マウブ音声発散) の仕組み

特徴抽出モデル：MERT

- **学習構造:** 音楽データ単体でマスク予測を行う自己教師あり学習
- **特化機能:** テキスト非依存で、**音高・リズム・音楽構造の捉え**に特化
- **比較手法:** 自然言語処理の評価手法（MAUVE）を音声へ転用

WAV File → MERT Encoder → 音楽構造特徴ベクトル

MAUVE による分布比較

$$r = aP + (1 - a)Q \quad D_1 = KL(Q \| r) \quad D_2 = KL(P \| r)$$

D_1, D_2 をプロットした曲線下の面積より距離を算出

- **P:** 生成曲の分布 / **Q:** 参照曲の分布 / **a:** 混合割合
- **KL:** 情報ダイバージェンス（分布間の一致度が大きいほど面積大）

MAD の値	意味
数値が小さい	生成曲の構造分布が参照に**近い（人の好みに適合）**
数値が大きい	生成曲の構造分布が参照から**遠い**

ACADEMIC RATIONALE

FAD と MAD を採用する学術的根拠

根拠 1：FAD と人の好みの対応 #4

音声生成モデル 12 種類を大規模被験者（2,500 人以上）に聴き比べさせた比較実験において、**CLAP を用いた FAD が「人の好みの順位」と最も高く対応**することが実証されています。

根拠 2：MAD のさらに高い相関性 #5

各種自動指標と人の嗜好データの対応度研究により、FAD の順位相関（0.14）に対し、**MAD は 0.62 という極めて高い相関**を示すことが実証されています。

評価指標	人の好みとの順位相関	本研究での立ち位置
FAD (フレシェ音声距離) #4	**0.14**	補助指標
MAD (マウブ音声発散) #5	**0.62**	**主指標**

評価方針の信頼性

MAD を**主指標**として精度を担保しつつ、FAD を**補助指標**として併記することで、生成能力の妥当性を多角的に証明します。

COMPARISON OF METRICS

FAD と MAD の比較まとめ

比較項目	FAD (フレシェ音声距離)	MAD (マウブ音声発散)
使用モデル	CLAP	MERT
モデル学習の特徴	音楽 × テキストの対照学習	音楽単体での自己教師あり学習
捉える側面	**意味的・雰囲気的な近さ**	**音楽的構造・パターンの近さ**
人の好みとの相関	0.14 (補助指標)	**0.62 (主指標)**
計算コスト	比較的軽量	MERT モデルが大きいためやや重い

💎 両指標を併用する学術的意義

仕組みの異なる2つの指標双方で良好な結果を示すことで、**「意味的（雰囲気）にも、音楽的構造（メロディ・リズム）にも参照（人の演奏）に極めて近い」**という二重の確固たる根拠を構築できます。

EVALUATION PIPELINE

自動評価の計算手順

1

MIDI 生成

プロンプトより作成（相手手法は同数ランダム）

2

音声化

共通の仮想楽器音源で全パート書き出し

3

参照音声準備

ロック・メタル系人作成MIDIを同音源化

4

特徴量変換

各音声を数値特徴ベクトルに変換

5

距離計算

生成・参照の分布間距離を算出

⚠ 評価実施上の注意点

・精度担保のため、評価は単曲ではなく **100曲以上をまとめて実施** します。
・音源による影響を排除するため、**全システムを同一の仮想楽器音源で鳴らして条件を均一化** します。

SUBJECTIVE EVALUATION METHOD

人が聴く評価の方法（主観評価）

評価の手順

- 本研究と比較相手の生成音声を評価者に提示
- 日本語プロンプト提示の上、各評価軸を 1〜5 で評定 #1
- 評価者1人あたり複数試聴（再生順序はランダム）
- **ブラインドテスト:** どちらの生成物かは完全非開示

評価軸と評価内容

評価軸	評価内容
旋律の豊かさ	旋律として調和的・音楽的に聞こえるか
リズムのまとまり	拍やリズムにまとまりがあるか
構造のまとまり	反復・展開など構成的なまとまりがあるか
技術的な完成度	突然の無音や不自然な跳躍が少ないか
総合満足度	総合的な聴感品質への満足度
雰囲気の一致	日本語プロンプトの雰囲気に合っているか *
明暗・激しさ	明暗・激しさが狙い通りか *

* 雰囲気・明暗激しさの一致は $M^{6}GPT^{3}$ との比較のみ実施

COMPARISON OVERVIEW

比較の対応関係

評価軸	この研究	M^6 GPT^3 #2	Whole-song-gen #3
基本 5 軸 (旋律・リズム・構造・完成度・総合) #1	✓	✓	✓
雰囲気の一致	✓	✓	文入力なし
明暗・激しさの一致	✓	✓	文入力なし
自動評価 (FAD / MAD) #4 #5	✓	✓	✓

M^6GPT^3 との入力条件の違いについて

M^6GPT^3 は英語で詳細な楽曲構造まで指定する条件で動作するのに対し、本研究は**「日本語の雰囲気文のみ」**で動きます。この条件差は論文中に明確に記した上で比較・議論を行います。

CLAIMS & NEXT STEPS

主張と今後の課題

本研究の主張

- **簡便な入力:** 専門用語のない日本語雰囲気文のみで狙い通りの数分間 MIDI を生成可能
- **基本品質:** 旋律・リズム・構造・完成度・総合の 5 軸で既存研究と同等以上を目指す
- **雰囲気制御:** 雰囲気・明暗・激しさの適合度で M^6GPT^3 を上回る評定を目指す

今後の課題

- **出力の安定化:** 数分規模の楽曲を破破なく安定して出力する技術改善
- **自動評価の実行:** 100 曲以上の生成を完了させ FAD・MAD を定量算出
- **主観評価の実施:** 被験者（評価者）を確保し、聴感印象評価実験を完遂

REFERENCES

出典・参考文献

[1] Chu et al., CIKM 2022

主観評価における基本 5 軸（旋律・リズム・構造・完成度・総合）の定義

[2] Pocwiardowski et al., 2024 (M^6GPT^3)

https://arxiv.org/abs/2409.12638

[3] Wang et al., 2024 (Whole-song-gen)

https://arxiv.org/abs/2405.09901

[4] arXiv:2506.19085

音声生成評価において CLAP を用いた FAD が人の好みと最も高く対応することを示す根拠論文

[5] arXiv:2503.16669

各種自動評価指標（FAD / MAD）と人の好みの順位相関比較（FAD: 0.14 vs MAD: 0.62）